

Manual de Usuario

Herramienta de Medición de Sesgos y Equidad — GobLab UAI

Guía paso a paso para usar la herramienta, interpretar cada gráfico y tabla, y decidir en qué métricas enfocarte. Todos los ejemplos usan el archivo de demostración `datos_demo_compas_es.csv` (versión en español del dataset COMPAS de reincidencia delictiva), incluido en esta misma carpeta.

Índice

1. ¿Qué es esta herramienta y para qué sirve?
2. Conceptos clave (glosario)
3. Prepara tus datos
4. El flujo de trabajo de un vistazo
5. Paso 1 — Cargar el archivo
6. Paso 2 — Análisis Exploratorio (EDA)
7. Paso 3 — Configuración del análisis
8. Paso 4 — Análisis de Sesgos
9. Paso 5 — Análisis de Equidad
10. Guía de métricas: cuándo usar cada una
11. Descargar el informe (PDF) y dar tu opinión
12. Modelos multiclase
13. En qué enfocarte: buenas prácticas y errores comunes
14. Preguntas frecuentes

1. ¿Qué es esta herramienta y para qué sirve?

Es una herramienta web que **mide el sesgo algorítmico** de un modelo de clasificación (por ejemplo, un modelo que predice riesgo de reincidencia, deserción escolar, o elegibilidad para un beneficio). No entrena modelos: **audita las predicciones que ya generó tu modelo**, comparando cómo se comporta entre distintos grupos de personas.

¿Para quién? Equipos de ciencia de datos del sector público que necesitan verificar que un modelo no discrimina de forma arbitraria.

Marco legal (Chile). La **Ley N.º 20.609** establece 16 categorías protegidas frente a la discriminación arbitraria (raza/etnia, sexo, edad, situación socioeconómica, religión, orientación sexual, discapacidad, etc.). Esta herramienta te ayuda a evaluar si tu modelo trata de forma equitativa a esos grupos, en línea con la guía *"Permitido Innovar"*.

Idea central. Un modelo puede tener buena precisión global y aun así **cometer sus errores de forma desigual** entre grupos. Por ejemplo, marcar de más como "reincidentes" a un grupo étnico. Esta herramienta cuantifica esas diferencias.

2. Conceptos clave (glosario)

TÉRMINO	QUÉ SIGNIFICA
Predicción del modelo	La columna con lo que tu modelo predijo (0/1). En el demo: <code>prediccion</code> (1 = el modelo predice que la persona reincidentirá).
Valor real	La columna con lo que realmente pasó (0/1). En el demo: <code>reincidio</code> (1 = efectivamente reincidentió).
Variable protegida	El atributo demográfico sobre el que evalúas la equidad (etnia, sexo, edad...).
Subgrupo	Cada valor de una variable protegida (p. ej. dentro de <code>etnia</code> : Afroamericano, Caucásico...).
Grupo de referencia	El subgrupo contra el que se comparan los demás. Todas las disparidades se miden respecto a él.
Disparidad	Cociente entre la métrica de un subgrupo y la del grupo de referencia. 1.00 = sin diferencia.
Tolerancia (τ)	Cuánta disparidad aceptas antes de declarar "inequitativo". <code>1.25x</code> = la regla del 80% (se tolera $\pm 25\%$).
Muestra mínima	Subgrupos con muy pocos casos (por defecto <50) se marcan "muestra insuficiente" y no deciden el veredicto, porque sus tasas son poco fiables.
Proxy	Una variable que, sin ser la protegida, está tan asociada a ella que la "esconde" (p. ej. la comuna puede ser proxy del nivel socioeconómico).

La matriz de confusión (base de todas las métricas), calculada **por cada subgrupo**:

	REINCIDIÓ (REAL = 1)	NO REINCIDIÓ (REAL = 0)
Modelo predice 1	Verdadero Positivo (VP)	Falso Positivo (FP)
Modelo predice 0	Falso Negativo (FN)	Verdadero Negativo (VN)

- Un **Falso Positivo** aquí = predecir que alguien reincidentirá cuando **no** lo hace (castigo injusto).

- Un **Falso Negativo** = no predecir reincidencia cuando **sí** ocurre.

3. Prepara tus datos

Tu archivo debe ser un **CSV** con, al menos, tres tipos de columna:

1. **Predicción del modelo** — binaria (**0 / 1**) o, para modelos multiclase, con más categorías.
2. **Valor real** — el resultado observado, en el mismo formato.
3. **Una o más variables protegidas** — categóricas (etnia, sexo, edad...).

Reglas importantes:

- Las variables protegidas deben ser **categóricas** (texto o pocas categorías). Columnas continuas (ingresos exactos, edad en años) conviene agruparlas en rangos.
- Evita valores faltantes en las columnas clave.
- Una columna identificador (**id**) es opcional y se ignora en el análisis.

Archivo de demostración (`datos_demo_compas_es.csv` , 7.214 filas):

ID	PREDICCION	REINCIDIO	ETNIA	SEXO	RANGO_EDAD
1	0	0	Otro	Masculino	Mayor de 45
5	1	0	Afroamericano	Masculino	Menor de 25
...					

4. El flujo de trabajo de un vistazo

Cargar CSV → EDA (explorar) → Configurar → Análisis de Sesgos → Análisis de Equidad
(4 pestañas) (columnas + (tablas + (disparidades +
tolerancia) valores por grupo) veredicto de equidad)

Cada paso se explica en detalle a continuación.

5. Paso 1 — Cargar el archivo

En la **portada** verás una introducción con el flujo en 4 pasos y las 4 métricas clave.

Herramienta · v2.0.0 · 4 métricas de equidad

Medición de *sesgos* y equidad estadística.

Evalúa si tu modelo de clasificación trata de forma equitativa a los distintos grupos de la población, y obtén un diagnóstico claro para construir sistemas más justos y responsables.

🎯 ¿Por qué utilizarla?


- Detecta sesgos en modelos de clasificación antes de ponerlos en producción.
- Compara el trato del modelo entre grupos protegidos (sexo, edad, etnia...).

📄 ¿En qué consiste?

- Mide tasas de disparidad con la metodología de Aequitas (Ghani, 2019).
- Cuatro métricas de error: FPR, FNR, FOR y FDR, por cada subgrupo.

📄 ¿Qué obtienes?

- Un veredicto de equidad por atributo, con gráficos y tablas claras.
- Un informe PDF descargable con todos tus resultados.



01 Carga tus datos — 02 Configura y elige la métrica — 03 Analiza el modelo — 04 Descarga tu informe

Formulario de inicio ("Comienza tu evaluación"). Debajo del correo (opcional) puedes indicar **desde dónde participas** (tipo de institución) y tu **tipo de usuario** (rol). Estos datos son **opcionales** y nos ayudan a entender quién usa la herramienta.

Comienza tu evaluación

Necesitas un archivo **.csv** o **.xlsx** con las predicciones del modelo, los valores reales y las variables protegidas.

Correo electrónico (opcional)

persona@servicio.gob.cl

¿Desde dónde participas?

Organismo público

Empresa privada

Institución académica

Organización de la sociedad civil

Persona independiente

Tipo de usuario

Ciencia de datos / IA

Desarrollo / Ingeniería

Dirección / jefatura

Investigación

Estudiante

Otro

☒ Acepto registrar mi participación (correo, institución y rol) para ayudar a mejorar la herramienta. Es **opcional**: puedes iniciar igualmente sin marcarla.

INICIAR EVALUACIÓN →

- Si marcas la casilla **"Acepto registrar mi participación"**, al pulsar **"Iniciar Evaluación"** se guarda tu registro (correo, institución y rol).
- Si **no** la marcas, igual entras a la herramienta: el registro es **opcional** y no condiciona el uso.

Tras iniciar, arrastra o selecciona tu archivo CSV en el área de carga. En cuanto se carga, la herramienta:

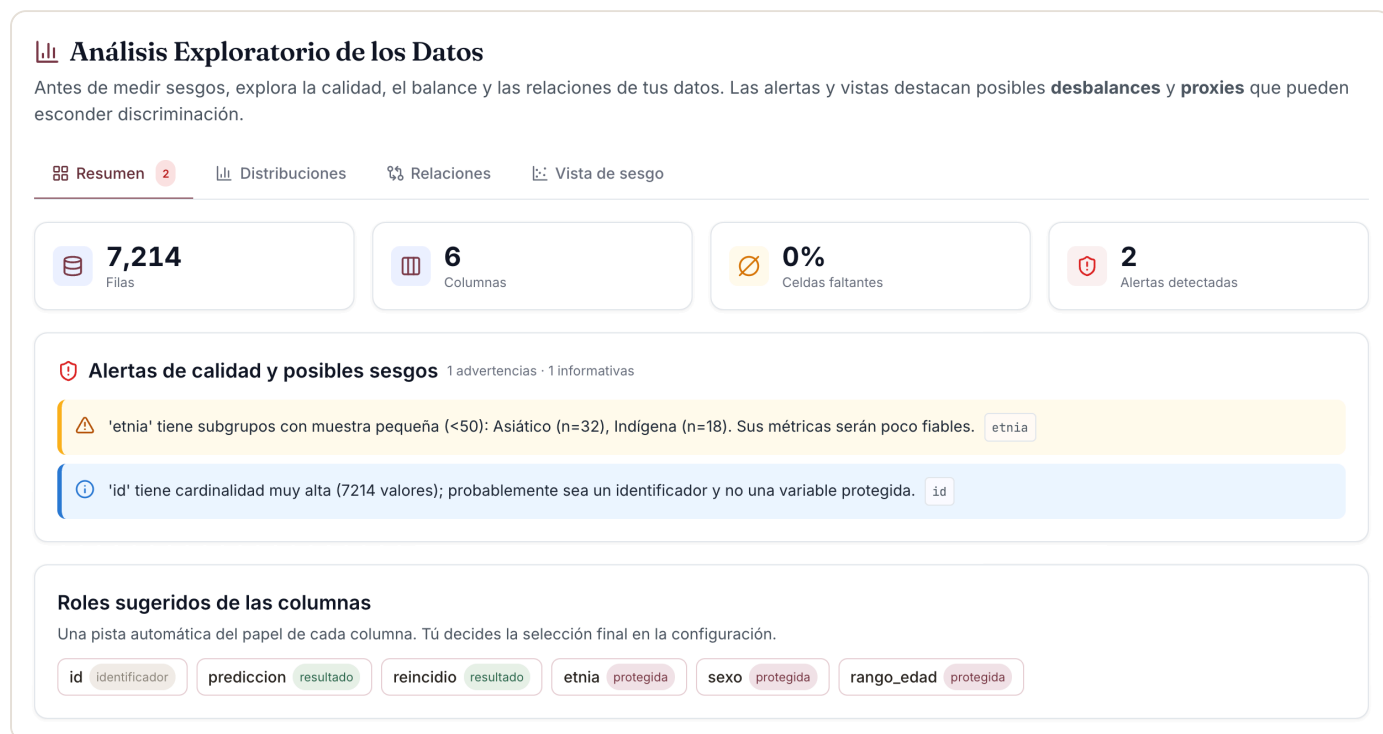
- Lee una vista previa de las columnas (para el paso de configuración).
- Ejecuta automáticamente el **Análisis Exploratorio (EDA)**, que aparece justo debajo.

Botón "Enviar feedback". En la esquina inferior derecha, en cualquier momento, hay un botón flotante para dejar un comentario o reportar un error. Es distinto de la encuesta de satisfacción (que aparece al descargar el informe).

6. Paso 2 — Análisis Exploratorio de los Datos (EDA)

Objetivo: entender tus datos y detectar problemas **antes** de medir la equidad. Un dato mal balanceado o un proxy oculto puede invalidar todo el análisis. El EDA se organiza en **cuatro pestañas**.

6.1 Pestaña «Resumen»



- **Tarjetas superiores:** número de filas, columnas, % de celdas faltantes y número de alertas detectadas.
- **Alertas de calidad y posibles sesgos** — el corazón del EDA. Cada alerta tiene color según su gravedad:
 - **Crítica** (rojo): p. ej. una columna con >20% de datos faltantes.
 - **Advertencia** (ámbar): subgrupos con muestra pequeña, categoría dominante (desbalance), proxy fuerte.
 - **Informativa** (azul): p. ej. una columna que parece un identificador.
 - En el demo verás: "'etnia' tiene subgrupos con muestra pequeña (<50): Asiático (n=32), Indígena (n=18). Sus métricas serán poco fiables." y "'id' tiene cardinalidad muy alta (7214 valores); probablemente sea un identificador y no una variable protegida."
- **Roles sugeridos:** una pista automática de qué es cada columna (resultado, protegida, identificador). **Es solo una sugerencia**; tú decides en la configuración.

En qué enfocarte: lee todas las alertas. Los subgrupos con muestra pequeña y los proxies son los que más pueden distorsionar (o esconder) un sesgo.

6.2 Pestaña «Distribuciones»

Muestra cómo se reparten los valores de cada variable.

📊 Análisis Exploratorio de los Datos


Antes de medir sesgos, explora la calidad, el balance y las relaciones de tus datos. Las alertas y vistas destacan posibles **desbalances** y **proxies** que pueden esconder discriminación.

📄 Resumen 2 📊 Distribuciones 📊 Relaciones 📊 Vista de sesgo

📊 Distribución por variable

Ver % predicción ▼

2 valores únicos 0% faltantes Balance: equilibrada (100%)



Perfil de columnas

id

7,214 valores únicos 0% faltantes

Numérica

mín: 1 máx: 11,001
media: 5501.26 mediana: 5509.50

prediccion

2 valores únicos 0% faltantes

Binaria

0 54.02%
1 45.98%

reincidio

2 valores únicos 0% faltantes

Binaria

0 54.93%
1 45.07%

etnia

6 valores únicos 0% faltantes

Categorica

Afroamericano 51.23%
Caucásico 34.02%
Hispano 8.83%
Otro 5.23%
Asiático 0.44%
Indígena 0.25%

sexo

2 valores únicos 0% faltantes

Binaria

Masculino 80.66%
Femenino 19.34%

rango_edad

3 valores únicos 0% faltantes

Categorica

25 a 45 56.96%
Mayor de 45 21.85%
Menor de 25 21.19%

- Selecciona una variable en el desplegable; alterna entre **conteo** y **%**.
- Para variables categóricas verás barras por categoría; para numéricas, un histograma.
- El **badge de balance** indica si la variable está *equilibrada*, *moderada* o *desbalanceada* (basado en la entropía). Una variable muy desbalanceada tendrá grupos minoritarios difíciles de evaluar.
- Las barras **ámbar** son subgrupos con muestra pequeña (<50 casos).
- Abajo, el **Perfil de columnas** resume cada columna (tipo, % faltantes, cardinalidad y su mini-distribución).

En qué enfocarte: revisa que cada variable protegida tenga grupos con suficientes casos. En el demo, **etnia** está *moderada*: Afroamericano y Caucásico dominan, mientras Asiático (32) e Indígena (18) son diminutos.

6.3 Pestaña «Relaciones»

Detecta **proxies**: variables que podrían sustituir a un atributo protegido.


📊 Análisis Exploratorio de los Datos

Antes de medir sesgos, explora la calidad, el balance y las relaciones de tus datos. Las alertas y vistas destacan posibles **desbalances** y **proxies** que pueden esconder discriminación.

📄 Resumen **2** 📊 Distribuciones 📊 Relaciones 📊 Vista de sesgo

📊 Mapa de asociaciones

Fuerza de asociación entre variables (Cramér's V, 0 = independientes, 1 = equivalentes). Los pares **oscuros** están muy relacionados: uno podría ser un **proxy** del otro (p. ej. una variable geográfica que "esconde" un atributo protegido).




📊 Explorador de relaciones

Proporción Conteo

Elige dos variables para ver cómo se distribuye una según la otra. Consejo: haz clic en una celda del mapa de arriba para cargar ese par.

Ver **reincidio** según **prediccion**



- El **mapa de asociaciones** mide la fuerza de relación entre cada par de variables (Cramér's V, de 0 = independientes a 1 = equivalentes).
- **Celdas oscuras = asociación fuerte = posible proxy.** Si una variable no protegida (p. ej. "comuna") aparece muy oscura junto a una protegida (p. ej. "etnia"), esa variable puede estar transmitiendo el sesgo de forma indirecta.
- Haz **clic en una celda** para cargar ese par en el **explorador de relaciones** de abajo, donde ves la relación como barras (por conteo o por proporción).

En qué enfocarte: cualquier par con $V \geq 0.5$ merece atención. En el demo la predicción (`prediccion`) está moderadamente asociada a `etnia` (≈ 0.27): una primera señal de que el modelo se comporta distinto según la etnia.

6.4 Pestaña «Vista de sesgo»

La vista más directa para **anticipar inequidades**.

📊 Análisis Exploratorio de los Datos

Antes de medir sesgos, explora la calidad, el balance y las relaciones de tus datos. Las alertas y vistas destacan posibles **desbalances** y **proxies** que pueden esconder discriminación.

📄 Resumen **2** 📊 Distribuciones 🔄 Relaciones 📈 Vista de sesgo


Vista preliminar de sesgo. Compara cómo se reparte el **resultado** (predicción o etiqueta) entre los grupos de una **variable protegida**. Diferencias grandes entre grupos anticipan posibles inequidades que el análisis formal confirmará.

🔄 Resultado por grupo

Proporción Conteo

Proporción de cada resultado dentro de cada grupo. Barras muy distintas entre grupos = posible sesgo.

Ver **prediccion** según **etnia**



📊 Intersecciones entre variables

Número de casos por combinación de dos variables. Las celdas **ámbar** tienen menos de 50 casos: son intersecciones poco fiables para medir equidad.

reincidio × **prediccion**

	0	1
0	2,681	1,216
1	1,282	2,035

- **Resultado por grupo:** elige un *resultado* (la predicción o el valor real) y una *variable protegida*. Cada barra muestra, dentro de cada grupo, la proporción de cada resultado (apilado al 100%).
- **Barras muy distintas entre grupos = posible sesgo.** En el demo se ve clarísimo: el modelo **predice reincidencia** para el **58,8% de los Afroamericanos** frente al **29,8% de los Hispanos** o el **21,0% de "Otro"**. Esa brecha es la que el análisis formal va a cuantificar y evaluar.
- **Heatmap de intersecciones:** cruza dos variables por número de casos, para detectar celdas **intersectivas** diminutas (p. ej. "mujeres asiáticas"), poco fiables para medir equidad.

En qué enfocarte: esta pestaña te dice *dónde mirar*. Si aquí ya ves una brecha grande, en el análisis de equidad muy probablemente saldrá "No Equitativo".

7. Paso 3 — Configuración del análisis

Paso 1: Configura tu Dataset

Asocia correctamente cada columna del archivo con su función en el análisis.

- **Columna de Predicciones:** selecciona la columna que contiene las predicciones generadas por tu modelo.
- **Columna de Valores Reales:** selecciona la columna que contiene las etiquetas reales u observadas.
- **Selecciona solo las variables protegidas:**
 - En el campo "Selecciona las columnas que quieres analizar", marca únicamente las variables protegidas que deseas evaluar por sesgos (por ejemplo: género, edad, situación socioeconómica).
 - No incluyas columnas de identificadores como ID, entity_id u otras variables que no representen atributos demográficos, ya que pueden interferir con los resultados del análisis.

Vista Previa de Datos

ID	PREDICCION	REINCIDIO	ETNIA	SEXO	RANGO_EDAD
1	0	0	Otro	Masculino	Mayor de 45
3	0	1	Afroamericano	Masculino	25 a 45
4	0	1	Afroamericano	Masculino	Menor de 25
5	1	0	Afroamericano	Masculino	Menor de 25
6	0	0	Otro	Masculino	25 a 45

Columna de Predicciones

prediccion

Columna de Valores Reales

reincidio

Selecciona las columnas que quieres analizar Seleccionar todas

etnia X sexo X rango_edad X

Seleccionar columna...

Paso 2: ¿Qué métrica debo mirar? (Opcional)

No todas las métricas importan por igual: depende de qué hace tu modelo. Responde estas preguntas y te diremos, en palabras simples, **en qué métrica enfocarte** y por qué. Está basado en el **árbol de decisión de Aequitas**.

Guía para elegir tu métrica (árbol de Aequitas)

¿Qué te preocupa más de la equidad de tu modelo?
Piensa en la diferencia: ¿te importa A CUÁNTAS personas de cada grupo elige el modelo, o EN QUÉ falla con cada grupo?

¿A cuántos elige de cada grupo? (representación)
Te fijas en la proporción de personas que el modelo marca como "sí" en cada grupo, sin mirar todavía si acertó o no.
Ejemplo: en una beca, que el porcentaje de seleccionados sea parecido entre hombres y mujeres.

→

¿En qué se equivoca con cada grupo? (errores)
Te fijas en si el modelo comete sus errores (marcar de más o dejar fuera) por igual en todos los grupos.
Ejemplo: que no marque por error como "riesgoso" a un grupo más que a otro.

→

Paso 3: ¿Cuánta diferencia entre grupos aceptas?

Comparamos cada grupo con un **grupo de referencia**. Si un grupo se comporta igual que la referencia, su valor es **1.00**. La tolerancia marca **hasta dónde** esa diferencia se considera aceptable antes de llamarla **inequitativa**.

Ejemplo con 1.25x: toleras hasta un **25% de diferencia**. Si el grupo de referencia tiene un 20% de error, un grupo con hasta 25% de error (1.25 veces) sigue siendo **equitativo**; si lo supera, pasa a **no equitativo**. Es la conocida **"regla del 80%"**.

Mueve el control: **más a la derecha** = más permisivo (aceptas mayores diferencias); **más a la izquierda** = más estricto.

1.25x

Con esta tolerancia, un grupo se considera **equitativo** si su valor queda entre **0.80** y **1.25** veces el del grupo de referencia (1.00 = sin diferencia). Fuera de ese rango, **no equitativo**.

Bajo el EDA aparece la configuración. Tres cosas que definir:

a) Columnas (Paso 1 en pantalla):

- **Predicciones del modelo** → en el demo, `prediccion`.
- **Valores reales** → `reincidio`.
- **Variables protegidas** → `etnia`, `sexo`, `rango_edad` (puedes elegir varias). No incluyas la columna `id`.

b) ¿Qué métrica debo mirar? (Paso 2, opcional): un **asistente interactivo** (basado en el árbol de decisión de Aequitas) que, respondiendo preguntas en lenguaje simple, te sugiere **en qué métrica enfocar**te y por qué. Primero distingue si te importa la **representación** (a cuántos elige de cada grupo) o los **errores** (en qué se equivoca); si son errores, si la predicción positiva **perjudica** (contexto punitivo → FPR/FDR) o **ayuda** (asistencial → FNR/FOR/TPR). Cada opción trae un ejemplo. Al final indica la **métrica principal** y las demás del mismo contexto a vigilar. Verás el árbol completo en la **sección 10**.

c) ¿Cuánta diferencia entre grupos aceptas? (Paso 3, la tolerancia): un multiplicador `x`. Cada grupo se compara con un **grupo de referencia**; si se comportan igual, su valor es **1.00**. La tolerancia marca hasta dónde esa diferencia se considera aceptable.

- `1.25x` (por defecto) = la clásica **"regla del 80%"**: se tolera hasta un 25% de diferencia. *Ejemplo*: si la referencia tiene 20% de error, un grupo con hasta 25% de error (`1.25x`) sigue siendo equitativo; por encima, "no equitativo".
- La ayuda muestra la **banda de equidad**: con `1.25x`, equitativo si la disparidad está entre **0.80 y 1.25**. Mover el control a la **derecha** = más permisivo; a la **izquierda** = más estricto.

Pulsa **"Analizar Modelo"**. Aparecen dos pestañas de resultados: **Análisis de Sesgos** y **Análisis de Equidad**.

8. Paso 4 — Análisis de Sesgos

Responde: **¿cómo se desempeña el modelo en cada subgrupo, por separado?** Aquí **todavía no se compara** entre grupos; solo se miden las tasas de cada uno.

8.1 Tablas

 **Total de instancias por subgrupo**

ID MODELO	UMBRAL SCORE	VALOR K	ATRIBUTO	VALOR ATRIBUTO	PREDICHOS POSITIVOS	PREDICHOS NEGATIVOS	FALSOS POSITIVOS	FALSOS NEGATIVOS	VERDADEROS NEGATIVOS	VERDAD POSITI
0	binary 0/1	2174	etnia	Afroamericano	2174	1522	805	532	990	1369
0	binary 0/1	8	etnia	Asiático	8	24	2	3	21	6
0	binary 0/1	854	etnia	Caucásico	854	1600	349	461	1139	505
0	binary 0/1	190	etnia	Hispano	190	447	87	129	318	103
0	binary 0/1	12	etnia	Indígena	12	6	3	1	5	9
0	binary 0/1	79	etnia	Otro	79	298	36	90	208	43
0	binary 0/1	591	sexo	Femenino	591	804	288	195	609	303
0	binary 0/1	2726	sexo	Masculino	2726	3093	994	1021	2072	1732
0	binary 0/1	1924	rango_edad	25 a 45	1924	2185	741	706	1479	1183
0	binary 0/1	394	rango_edad	Mayor de 45	394	1182	181	285	897	213
0	binary 0/1	999	rango_edad	Menor de 25	999	530	360	225	305	639

Consejo: desliza la tabla horizontalmente para ver todas las columnas.

Tabla "Total de instancias por subgrupo" — los conteos crudos por subgrupo. Es la base: aún no mide sesgo, sirve para entender volumen y balance.

COLUMNA	QUÉ SIGNIFICA
Atributo / Valor del Atributo	La variable protegida y el subgrupo.
Predichos Positivos (PP)	A cuántas personas el modelo predijo "positivo" (VP + FP).
Predichos Negativos (PN)	A cuántas predijo "negativo" (VN + FN).
Falsos Positivos (FP)	Marcadas como positivas por error (eran negativas).
Falsos Negativos (FN)	Positivas que el modelo no detectó.
Verdaderos Negativos (VN) / Verdaderos Positivos (VP)	Aciertos en negativos / positivos.
Etiquetas Positivas / Negativas del Grupo	Cuántas eran realmente positivas / negativas.
Tamaño Grupo	Total de personas en el subgrupo.
Total Entidades	Total en toda la variable protegida.
ID Modelo · Umbral Score · k	Columnas técnicas internas; puedes ignorarlas.

¿Qué mirar? El **Tamaño Grupo** (para detectar subgrupos pequeños, <50, poco fiables) y el balance de casos positivos reales.


Tabla "Métricas de error para cada subgrupo" — convierte los conteos en **tasas** (0 a 1) para poder comparar grupos de distinto tamaño.

MÉTRICA	FÓRMULA (EN PALABRAS)	QUÉ RESPONDE
Exactitud	aciertos / total	¿Qué proporción acertó en el subgrupo?
TPR — Sensibilidad/Recall	VP / (VP+FN)	De los positivos reales, ¿a cuántos detectó?
TNR	VN / (VN+FP)	De los negativos reales, ¿a cuántos identificó bien?
FPR — Falsos Positivos	FP / (FP+VN)	De los que no eran positivos, ¿a cuántos marcó por error?
FNR — Falsos Negativos	FN / (FN+VP)	De los positivos reales, ¿a cuántos se le escapó?
FOR — Falsas Omisiones	FN / (FN+VN)	De los marcados negativos, ¿cuántos eran positivos?
FDR — Falsos Descubrimientos	FP / (FP+VP)	De los marcados positivos, ¿cuántos estaban mal?
NPV	VN / (VN+FN)	De los marcados negativos, ¿cuántos acertó?
Precisión (PPV)	VP / (VP+FP)	De los marcados positivos, ¿cuántos acertó?
PPR	PP / Tamaño Grupo	¿A qué fracción del grupo marcó como positivo?
Prevalencia Predicha	PP / total predichos	Peso del grupo entre los positivos predichos.
Prevalencia	Etiquetas Positivas / Tamaño Grupo	¿Qué fracción era realmente positiva?

¿Qué mirar? Compara **la misma métrica entre subgrupos**. Las 4 que deciden el veredicto de equidad son **FPR, FNR, FOR y FDR** (las de error).

Estas dos tablas son **absolutas**: describen a cada subgrupo por sí mismo y **no dependen del grupo de referencia** (ver [sección 9](#)).

8.2 Gráfico de valores absolutos



- Elige una **métrica** (p. ej. *Tasa de Falsos Positivos, FPR*) y una **variable** (o "Todas las variables").
- Cada barra es el **valor de esa métrica en un subgrupo**, agrupadas por atributo. La etiqueta muestra el valor y el tamaño del grupo (**Num**).
- El **color** codifica el tamaño del grupo (más oscuro = grupo más grande).

Cómo leerlo (ejemplo real del demo): la FPR de **etnia** es **0.45 en Afroamericano**, **0.24 en Caucásico** y **0.15 en "Otro"**. Es decir: entre las personas que **no** reincidieron, el modelo marcó erróneamente como "reincidente" a casi la mitad de los afroamericanos, pero solo a ~1 de cada 7 del grupo "Otro". Esa es la huella del sesgo — pero para juzgarla necesitamos compararla contra una referencia, que es lo que hace la siguiente pestaña.

En qué enfocarte: identifica la métrica que más importa en tu caso (ver **sección 10**) y observa qué tan distintos son sus valores entre grupos.

9. Paso 5 — Análisis de Equidad

Responde: **¿son justas esas diferencias?** Compara cada subgrupo con el grupo de referencia y emite un veredicto.

9.1 Elegir el grupo de referencia

- **Grupo Mayoritario** (por defecto): el subgrupo con más casos (en el demo, Afroamericano en **etnia**).
- **Grupo con Mejor Desempeño**: el de menor error. **Ojo**: en este modo la referencia se elige **por cada métrica** (el mejor grupo en FPR puede no ser el mejor en FNR), así que puede **variar por métrica**.
- **Personalizado**: tú eliges el subgrupo de referencia (útil si hay un grupo de comparación definido por política).

Vista previa antes de analizar. Debajo de la selección de método, y **antes** de pulsar "*Analizar Equidad*", la herramienta muestra un recuadro "**Grupo de referencia que se usará**" con el grupo elegido por atributo (p. ej. **etnia → Afroamericano**). En *Mejor Desempeño* muestra el desglose por métrica. Así ves qué referencia se aplicará antes de ejecutar.

Todas las disparidades se miden **respecto a ese grupo**, que por construcción tiene disparidad **1.00** y aparece marcado con "**(ref)**" en la tabla de disparidades. Tras analizar, el panel "**¿Contra qué se compara cada grupo?**" confirma la referencia usada por atributo y el método aplicado.

¿Y si cambio el grupo de referencia? Al cambiar el método y pulsar "*Analizar Equidad*" se actualizan **solo las cosas relativas**: la tabla de **disparidades**, el **gráfico de disparidad**, la marca "**(ref)**" y los **veredictos**. Las tablas absolutas (*Total de instancias* y *Métricas de error*) y la pestaña *Análisis de Sesgos* **no cambian**, porque los conteos y tasas de cada grupo no dependen de con quién se comparen. Si "no viste cambios", probablemente mirabas una tabla absoluta.

9.2 Tabla de disparidades y gráfico (treemap)

Gráfico de Disparidad Detallado

En esta sección puedes analizar una métrica de desempeño del modelo desagregada por una variable protegida. Esto te permitirá identificar posibles disparidades en el funcionamiento del modelo entre distintos grupos.

- **Métrica:** selecciona una métrica de interés (por ejemplo, tasa de falsos positivos, precisión, sensibilidad, etc.). La métrica que elijas debe estar alineada con el objetivo de tu proyecto y con la forma en que se definen las categorías positivas y negativas en tu modelo.
- **Variable protegida:** selecciona la variable sobre la que deseas evaluar el sesgo. También puedes elegir "todas las variables" para visualizar el desglose completo.

Puedes repetir este proceso para distintas métricas y variables. La herramienta realiza el análisis una métrica a la vez, pero puedes volver a esta pestaña cuantas veces necesites.

Una vez realizada tu selección, haz clic en "Actualizar gráfico" para ver los resultados desagregados.

Disparidad en Tasa de Falsos Positivos (FPR)

Todas las variables

Actualizar Gráfico

Disparidad para Disparidad en Tasa de Falsos Positivos (FPR)

Disparidad de Tasa de Falsos Positivos A TRAVÉS DE ATRIBUTOS



No etiquetado arriba:
etnia: Hispano, 0.48; etnia: Otro, 0.33; etnia: Asiático, 0.19; etnia: Indígena, 0.84

- La **tabla de disparidades** muestra, por métrica, el cociente $\frac{\text{métrica_subgrupo}}{\text{métrica_referencia}}$.
- El **treemap** ("gráfico de cuadros") visualiza esas disparidades: cada rectángulo es un subgrupo, coloreado por su disparidad en una escala que va de azul (bajo) a café (alto), centrada en 1.0. El grupo de referencia aparece marcado "(ref)".
- Los subgrupos muy pequeños que no caben se listan como "No etiquetado arriba".

¿Cómo se calcula la disparidad? Para cada métrica y subgrupo:

$$\text{Disparidad}(\text{grupo}) = \text{Métrica}(\text{grupo}) \div \text{Métrica}(\text{grupo de referencia})$$

Ejemplo real ($\tau = 1.25$, referencia = Afroamericano): FPR de Caucásico = 0.24; FPR de Afroamericano = 0.45 $\rightarrow$ disparidad = $0.24 \div 0.45 = 0.52$ (Caucásico tiene alrededor de la mitad de falsos positivos que la referencia).

Cómo leer una disparidad:

- **= 1.00** $\rightarrow$ el subgrupo se comporta igual que la referencia.
- **> 1.00** $\rightarrow$ el subgrupo tiene **más** de esa métrica (más error, si la métrica es un error).
- **< 1.00** $\rightarrow$ el subgrupo tiene **menos**.

Cómo leer el gráfico de disparidad (qué esperar y qué no):

- **Sin sesgo:** todos los subgrupos **cerca de 1.00**, dentro de la banda equitativa (0.80–1.25 con $\tau = 1.25$).
- **Señal de alerta:** cuadros **lejos de 1.00**. Valores altos ($> \tau$) = el subgrupo sufre **más** de ese error; bajos ($< 1/\tau$) = sufre menos (o la referencia está peor).
- **Lo que no deberías ver** en un modelo equitativo: disparidades grandes y sistemáticas (varias métricas fuera de rango) concentradas en un mismo grupo.
- Revisa **una métrica a la vez**, alineada con tu contexto (punitivo $\rightarrow$ FPR/FDR; asistencial $\rightarrow$ FNR/FOR).

9.3 Ajustar la tolerancia y recalcular

Ajustar Tolerancia y Recalcular

La tolerancia marca cuánta **diferencia** aceptas entre un grupo y el grupo de referencia antes de llamarla inequitativa. **Más a la derecha** = más permisivo; **más a la izquierda** = más estricto.

Cómo leerlo: con **1.25x**, un grupo es **equitativo** si su valor queda entre **0.80 y 1.25** veces el del grupo de referencia (1.00 = sin diferencia). Ej.: 1.25x tolera hasta un 25% de diferencia (la "regla del 80%").

1.25x

Rango equitativo actual: 0.80 – 1.25. Pulsa **Recalcular** para aplicar el nuevo valor.

Recalcular

- Mueve el **slider de tolerancia** (formato **x**) y pulsa **"Recalcular"**. Verás la banda de equidad actualizada ("equitativo si la disparidad está entre $1/\tau$ y τ ").
- Subir la tolerancia hace el criterio más permisivo; bajarla, más estricto.

9.4 Resumen de Equidad y "¿Por qué estas conclusiones?"

- **Resumen de Equidad por Atributo:** un veredicto por variable protegida — **Equitativo** (verde) o **No Equitativo** (rojo). Un atributo es "No Equitativo" si **algún subgrupo fiable** supera la tolerancia en alguna de las métricas de error (FPR, FNR, FOR, FDR).
- **¿Por qué estas conclusiones?** — el panel más útil. Para cada atributo inequitativo, lista **qué subgrupos** lo causan, con la **métrica de mayor disparidad** y su valor, y **cuáles se excluyeron por muestra insuficiente**.

 **Resumen de Equidad por Atributo**

ATRIBUTO	CONCLUSIÓN EQUIDAD
etnia	No Equitativo
rango_edad	No Equitativo
sexo	No Equitativo

¿Por qué estas conclusiones?

Detalle de los subgrupos que determinan cada veredicto, con la tolerancia actual de 1.25×. Los subgrupos con menos de 50 casos se consideran de **muestra insuficiente** y no afectan la conclusión.

etnia: **No Equitativo**

- **Caucásico** (n=2454) — mayor disparidad en **FPR** = 0.52×
- **Hispano** (n=637) — mayor disparidad en **FPR** = 0.48×
- **Otro** (n=377) — mayor disparidad en **FPR** = 0.33×

No evaluados por muestra insuficiente: Asiático (n=32), Indígena (n=18).

sexo: **No Equitativo**

- **Femenino** (n=1395) — mayor disparidad en **FOR** = 0.73×

rango_edad: **No Equitativo**

- **Mayor de 45** (n=1576) — mayor disparidad en **FPR** = 0.50×
- **Menor de 25** (n=1529) — mayor disparidad en **FPR** = 1.62×

Ejemplo real del demo (tolerancia 1.25×, referencia mayoritaria):

SUBGRUPO (ETNIA)	N	FPR	DISPARIDAD FPR	¿CUENTA?
Afroamericano (Ref)	3.696	0.45	1.00	—
Caucásico	2.454	0.24	0.52	sí → No Equitativo
Hispano	637	0.22	0.48	sí → No Equitativo
Otro	377	0.15	0.33	sí → No Equitativo
Asiático	32	0.09	0.19	excluido (muestra <50)
Indígena	18	0.38	0.84	excluido (muestra <50)

Interpretación: **etnia** sale **No Equitativo** porque grupos reales (Caucásico, Hispano, Otro) tienen tasas de falsos positivos muy por debajo del grupo de referencia. Traducido: el modelo **marca erróneamente como reincidentes a los afroamericanos con mucha más frecuencia** que a los demás. Los grupos diminutos (Asiático, Indígena) se **excluyen** del veredicto porque sus tasas, con tan pocos casos, no son fiables.

9.5 Test de Equidad Estadística por Atributo

Una tabla complementaria que muestra el veredicto **por cada tipo de paridad** (no solo la conclusión global), útil para un análisis más fino.

10. Guía de métricas: cuándo usar cada una

No todas las métricas importan por igual: **depende de qué acción desencadena la predicción de tu modelo**. El siguiente **árbol de decisión** (el mismo asistente del Paso 2, en formato visual) resume cómo elegir la métrica en la que enfocarte:

¿En qué métrica enfocar tu análisis de equidad?

Guía de decisión en español — inspirada en el árbol de Aequitas

¿Qué te preocupa más de la equidad de tu modelo?

LA REPRESENTACIÓN

A cuántas personas elige de cada grupo

¿Cómo repartir la selección?

Igual número de cada grupo

PPR

Paridad de Selección

Marca como "positivo" a una proporción similar en cada grupo.

Proporcional al tamaño del grupo

PP

Paridad Demográfica

La selección es proporcional a la presencia de cada grupo.

No mira aciertos ni errores:

solo cuántas personas de cada grupo selecciona el modelo, sin importar si acertó.

LOS ERRORES DEL MODELO

En qué se equivoca: que falle por igual en todos los grupos

⚠ **Antes de medir errores:**

¿confías en las etiquetas (los valores reales)? Si podrían venir sesgadas, revisa el origen de los datos.

Cuando el modelo predice "positivo", ¿qué recibe la persona?

PUNITIVO

Perjudica: vigilar, negar, sancionar

Cuida los **FALSOS POSITIVOS**

FPR

Tasa de Falsos Positivos

PRINCIPAL

Que no señalen por error a quien NO correspondía.

FDR

Tasa de Falsos Descubrimientos

De a quienes se aplica la medida, que pocos estén mal.

ASISTENCIAL

Ayuda: apoyo, cupo, admisión

Cuida los **FALSOS NEGATIVOS**

FNR

Tasa de Falsos Negativos

PRINCIPAL

Que no se le escape la ayuda a quien SÍ la necesita.

FOR

Tasa de Falsas Omisiones

Que "no dar ayuda" sea una decisión acertada por grupo.

TPR

Sensibilidad (Recall)

Si solo ayudas a una fracción: cubrir a una proporción similar por grupo.

Prioriza la métrica PRINCIPAL de tu contexto y revisa las demás del mismo grupo · Disparidad cercana a 1.00 = trato equitativo · GobLab UAI

Cómo usarlo:

- **Representación** (a cuántos elige de cada grupo) → **PPR** (mismo número por grupo) o **Paridad Demográfica / Prevalencia Predicha** (proporcional al tamaño).
- **Errores · contexto punitivo** (la predicción positiva perjudica: vigilar, negar, sancionar) → **FPR** (principal) y **FDR**.
- **Errores · contexto asistencial** (la predicción positiva da un beneficio: apoyo, cupo, admisión) → **FNR** (principal), **FOR** y, si solo puedes atender a una fracción, **TPR**.

Como regla, primero pregúntate:

¿Un resultado "positivo" del modelo lleva a una acción **PUNITIVA** (vigilancia, negación, detención) o a un **BENEFICIO** (apoyo, recurso, admisión)?

SI TE IMPORTA QUE...	ENFÓCATE EN	DEFINICIÓN	EN EL DEMO
No se castigue de más a un grupo (falsos positivos)	FPR (Tasa de Falsos Positivos)	De los que no eran positivos, cuántos marcó como positivos	Marcar "reincidente" a quien no reincide
Las intervenciones positivas sean precisas por grupo	FDR (Tasa de Falsos Descubrimientos)	De los marcados positivos, cuántos estaban mal	Detenidos preventivamente por error
No se deje fuera a un grupo que lo necesita (falsos negativos)	FNR (Tasa de Falsos Negativos)	De los que sí eran positivos, cuántos se le escaparon	No detectar a quien sí reincidirá
Un resultado negativo no niegue un beneficio injustamente	FOR (Tasa de Falsas Omisiones)	De los marcados negativos, cuántos eran realmente positivos	Clasificar como "seguro" a quien no lo era
La cobertura sea pareja	TPR (Sensibilidad)	De los positivos reales, cuántos detectó	—
La tasa de selección sea pareja	Prevalencia predicha / PPR	Proporción de positivos que predice por grupo	Paridad estadística / demográfica

Regla práctica de la herramienta: el **veredicto global** de equidad se basa en las cuatro métricas de **error** — **FPR, FNR, FOR, FDR** — porque son las más relevantes para daños concretos y son independientes del tamaño del grupo. La *Paridad Estadística* (PPR) se muestra aparte, pues depende mucho del tamaño de cada grupo.

Ejemplo de decisión (demo de reincidencia): como una predicción positiva puede llevar a una **medida punitiva**, la métrica más crítica es la **FPR** (no castigar de más a un grupo por errores del modelo). Y efectivamente ahí aparece el sesgo.

11. Descargar el informe (PDF) y dar tu opinión

Al final de los resultados, la tarjeta "**Tu informe está listo**" genera un **PDF** descargable con todo tu análisis, con la misma identidad visual de la herramienta. El informe incluye:

1. **Página inicial — Análisis exploratorio (EDA):** panorama (filas, columnas, % de celdas faltantes, número de alertas), la tabla de **alertas de calidad y posibles sesgos** (con su nivel) y los **roles sugeridos** de las columnas.
2. **Métrica recomendada a observar:** si usaste el asistente del Paso 2, se destaca la métrica sugerida.
3. **Resumen del análisis:** registros, variables protegidas, tolerancia, método de **grupo de referencia** y tipo de modelo.
4. **Resumen de Equidad por Atributo** (Equitativo / No Equitativo).
5. **Grupo de referencia por atributo** (qué grupo se usó como base).

6. **Disparidades por atributo** (FPR/FNR/FOR/FDR), con la fila de referencia marcada **"(ref)"**.

7. **Gráficos** del análisis.

Encuesta de satisfacción (opcional). Al pulsar **"Descargar informe PDF"** aparece una breve encuesta con dos opciones:

- **"Enviar y descargar"**: envía tu valoración y descarga el PDF.
- **"Omitir y descargar"**: descarga el PDF **sin** responder.

Tu opinión es anónima (salvo que dejes tu correo) y nos ayuda a mejorar. Para comentarios o reportar errores en cualquier momento, usa el botón flotante **"Enviar feedback"** (esquina inferior derecha).

12. Modelos multiclase

Si tu predicción/valor real tiene **más de dos categorías** (p. ej. riesgo **Bajo** / **Medio** / **Alto**), la herramienta lo detecta y usa la estrategia **"uno-contra-el-resto"**: evalúa cada clase por separado frente al resto.

- Aparece un **selector de clase** arriba de los resultados. Al cambiar de clase, todas las tablas y gráficos se actualizan a esa clase.
- Un **resumen global** indica, con badges, si cada atributo es inequitativo en **alguna** clase.

Todo lo demás (grupo de referencia, tolerancia, interpretación) funciona igual, pero referido a la clase seleccionada.

13. En qué enfocarte: buenas prácticas y errores comunes

Buenas prácticas

- **Empieza por el EDA.** Si hay proxies o grupos diminutos, tenlo presente al leer los resultados.
- **Elige la métrica según el daño** que produce un error (sección 10), no midas todo a ciegas.
- **Usa el panel "¿Por qué estas conclusiones?"** para saber qué subgrupo y qué métrica están causando la inequidad. Ese es tu punto de acción.
- **Documenta la tolerancia elegida** (1.25x / regla 80% es un estándar razonable) y justifícala.
- **Trata los grupos con muestra insuficiente aparte:** no ignores que existen, pero recuerda que sus tasas son inestables.

Errores comunes

- Confundir **valores absolutos** (Análisis de Sesgos) con **disparidades** (Análisis de Equidad). El primero mide cada grupo solo; el segundo compara.
- Concluir "el modelo es justo" mirando solo la **precisión global**. Un modelo preciso en promedio puede ser muy inequitativo por grupos.

- Interpretar una disparidad <1 como "bueno". Significa **menos** de esa métrica en el subgrupo, lo que puede ser bueno o malo según la métrica (menos falsos positivos es bueno; menos verdaderos positivos es malo).
 - Dejar que un grupo de 15 personas "decida" el veredicto. Por eso existe la **muestra mínima**.
 - Incluir la columna **id** como variable protegida (tiene cardinalidad altísima y no aporta).
-

14. Preguntas frecuentes

¿La herramienta guarda mis datos? No. Los datos se procesan y se descartan; no se almacenan.

¿Por qué **etnia sigue saliendo "No Equitativo" aunque suba mucho la tolerancia?** Porque la disparidad es **real y grande** en grupos reales (no solo en los pequeños). Usa el panel "¿Por qué?" para ver qué subgrupos la causan.

¿Qué formato debe tener la predicción? Binaria **0/1** para modelos de dos clases, o varias categorías para multiclase. El valor real, en el mismo formato.

¿Puedo evaluar varias variables protegidas a la vez? Sí, selecciónalas todas en la configuración; cada una recibe su propio veredicto.

¿Qué significa "muestra insuficiente"? Que ese subgrupo tiene menos casos que el umbral (por defecto 50) y, por tanto, no se usa para decidir el veredicto (pero sigue visible en las tablas).

GobLab UAI — Escuela de Gobierno, Universidad Adolfo Ibáñez. Herramienta de apoyo a la Ley N.º 20.609 y a la guía "Permitido Innovar".